Trabajo Práctico: Diseño y Optimización de Bases de Datos

Enunciado General

Una cadena de hoteles desea desarrollar una base de datos para gestionar la información de sus hoteles y el sistema de reservas. La organización trabaja exclusivamente mediante reservas. De cada hotel se desea almacenar información general, ubicación, medios de contacto y puntos de interés cercanos. Los hoteles ofrecen diferentes tipos de habitaciones, cada una con determinadas comodidades.

Los huéspedes pueden realizar reservas indicando la habitación, fecha de inicio y fecha de salida. La tarifa será establecida únicamente cuando la reserva sea confirmada. El sistema deberá contemplar que una misma habitación no pueda ser reservada para períodos que se superpongan.

De cada huésped se desea almacenar sus datos personales, teléfonos, correos electrónicos y domicilio, contemplando que pueda tener más de un medio de contacto.

A partir de este escenario, los estudiantes deberán diseñar, implementar, cargar, analizar, medir y optimizar una base de datos que permita resolver las necesidades planteadas y, simultáneamente, estudiar el comportamiento del motor de base de datos ante diferentes volúmenes de información, estrategias de indexación, consultas, cargas de trabajo, configuraciones y situaciones de concurrencia.

Parte I — Analisis del Problema y Diseño de Datos

1. Análisis del dominio

Analizar detalladamente el escenario planteado e identificar las entidades, atributos, reglas de negocio, restricciones y relaciones necesarias para representar hoteles, habitaciones, huéspedes, contactos, domicilios, reservas, tarifas, comodidades, ubicaciones y puntos de interés. Identificar explícitamente las reglas que deben cumplirse para evitar inconsistencias, incluyendo la imposibilidad de superponer reservas para una misma habitación.

2. Modelo relacional

Presentar las relaciones, atributos, claves primarias, claves foráneas y restricciones. Justificar las transformaciones realizadas.

3. Normalización

Aplicar las formas normales correspondientes. Analizar dependencias funcionales y justificar que el modelo evita redundancias y anomalías de inserción, modificación y eliminación.

4. Integridad y reglas de negocio

Definir restricciones de integridad necesarias: NOT NULL, UNIQUE, CHECK cuando corresponda, claves foráneas, integridad referencial y demás restricciones. Determinar qué reglas deben garantizarse desde la base y cuáles podrían corresponder a la aplicación.

5. Normalización versus desnormalización
Analizar conceptualmente situaciones en las que una desnormalización controlada podría mejorar determinadas consultas. Proponer al menos un escenario, justificarlo y, cuando sea posible, medir experimentalmente sus efectos sin comprometer la integridad de los datos.

Parte II — Diseño Físico y Almacenamiento

6. Implementación física
Crear las tablas de la base de datos utilizando PostgreSQL, MySQL o MariaDB. Documentar el script completo de creación.

7. Selección de tipos de datos
Para cada atributo determinar y justificar el tipo de dato utilizado. Analizar especialmente INT/BIGINT,CHAR/VARCHAR/TEXT,DATE/DATETIME/TIMESTAMP,DECIMAL/FLOAT/ DOUBLE y BOOLEAN, considerando volumen, precisión, almacenamiento y comportamiento.

8. Claves y restricciones físicas
Implementar claves primarias, foráneas, restricciones UNIQUE, CHECK y demás mecanismos de integridad que correspondan. Explicar el impacto de las decisiones adoptadas.

9. Motor y estructuras de almacenamiento
Investigar el motor o mecanismo de almacenamiento utilizado. En el caso de MySQL/MariaDB, analizar particularmente InnoDB, sus características transaccionales, índices, bloqueos y relación con el almacenamiento.

10. Estrategias de almacenamiento
Analizar el impacto del almacenamiento físico sobre el rendimiento: disco, I/O, tamaño de tablas, tamaño de índices y crecimiento de los datos. Documentar las características del entorno de experimentación.

Parte III — Índices y Estructuras de Acceso

11. Estrategia general de índices
Definir una estrategia de índices para la base. Incluir índices de clave primaria, índices simples, índices UNIQUE, índices compuestos e índices sobre claves foráneas cuando corresponda. Para cada índice indicar columnas, consultas objetivo y justificación.

12. Arboles B-Tree y B+Tree
Investigar y explicar el funcionamiento de B-Tree/B+Tree. Comparar búsqueda secuencial y búsqueda mediante índice. Explicar altura, nodos, páginas, acceso a disco y costo de búsqueda.

13. Otros tipos de índices
Investigar otros tipos de estructuras de indexación disponibles en el motor seleccionado o en otros motores. Explicar sus características, ventajas, limitaciones y casos de utilización.

14. Índices compuestos y regla del prefijo izquierdo
Crear diferentes índices compuestos. Experimentar con distintos órdenes de columnas y determinar mediante EXPLAIN en qué consultas puede utilizarse el índice y en cuáles no. Explicar experimentalmente la regla del prefijo izquierdo.

15. Índices de cobertura
Diseñar al menos un índice de cobertura para una consulta relevante. Comparar la consulta con y sin dicho índice y analizar el plan de ejecución, acceso a la tabla y rendimiento.

16. Índices funcionales o basados en expresiones
Investigar si el motor seleccionado soporta índices funcionales o expresiones indexadas. Implementar un ejemplo o, si no está disponible, proponer una estrategia equivalente y explicar sus implicancias.

17. Cardinalidad y selectividad
Analizar las columnas e identificar alta/baja cardinalidad y alta/baja selectividad. Determinar la relación entre estos conceptos y la utilidad de un índice.

18. ¿Por qué no indexar todos los campos?
Crear dos escenarios: uno con estrategia de índices limitada y otro con una cantidad elevada de índices. Comparar consultas de lectura y operaciones INSERT, UPDATE y DELETE. Explicar ventajas, costos de mantenimiento y situaciones en las que un índice puede resultar perjudicial.

Parte IV — Datos, Carga masiva y Metodología experimental

19. Generación de datos de prueba
Diseñar un mecanismo reproducible para generar datos de prueba. La distribución debe ser razonablemente realista para el dominio de reservas y documentar criterios utilizados para hoteles, huéspedes, habitaciones, fechas, estados y reservas.

20. Carga masiva
Realizar una carga masiva alcanzando como mínimo 6 millones de registros en la tabla seleccionada para el experimento principal. Documentar procedimiento, herramientas, tiempos, tamaño final y dificultades encontradas.

21. Distribución de los datos
Analizar la distribución de los valores y su relación con cardinalidad, selectividad y comportamiento del optimizador. Identificar posibles distribuciones sesgadas y explicar sus consecuencias.

22. Metodología de benchmarking
Definir una metodología reproducible para las pruebas. Documentar hardware, CPU, RAM, almacenamiento, versión del motor, configuración, volumen de datos, cantidad de conexiones, consultas y condiciones de ejecución.

23. Cold Cache y Warm Cache
Analizar el comportamiento de las consultas cuando los datos no se encuentran en memoria y cuando ya fueron cargados en caché. Comparar resultados y explicar cómo evitar conclusiones incorrectas por efecto de la caché.

Parte V — SQL y Consultas del Sistema

24. Consultas SQL de dificultad progresiva
Desarrollar consultas utilizando fechas, INNER JOIN, LEFT JOIN, EXISTS, CASE WHEN, GROUP BY, ORDER BY, LIMIT, funciones de agregación y subconsultas cuando corresponda.

25. Consultas complejas
Desarrollar al menos 15 consultas complejas que representen situaciones reales del sistema. Al menos 5 deberán involucrar cuatro o más tablas. Incluir disponibilidad, reservas por período, hoteles con mayor cantidad de reservas, huéspedes, ocupación, puntos de interés, consultas históricas, rankings y análisis temporales.

26. Consultas sobre disponibilidad
Diseñar consultas que permitan determinar si una habitación está disponible para un período solicitado, considerando la superposición de intervalos de fechas y las reglas de negocio.

27. Consultas históricas y temporales
Realizar consultas sobre reservas futuras, históricas, por mes, año, rango de fechas y períodos de ocupación. Comparar diferentes formas de expresar los filtros temporales.

28. Transporte de datos
Comparar consultas que devuelvan pocas filas, muchas filas, muchas columnas y grandes cantidades de información. Analizar SELECT * frente a seleccionar únicamente las columnas necesarias y estudiar LIMIT y diferentes estrategias de paginación.

Parte VI — Optimizador, SARGabilidad y Planes de Ejecución

29. EXPLAIN y EXPLAIN ANALYZE
Analizar las consultas mediante EXPLAIN y, cuando la versión utilizada lo permita, EXPLAIN ANALYZE. Identificar índices posibles y utilizados, cantidad estimada y real de filas cuando esté disponible, tipo de acceso, orden de ejecución, ordenamientos, tablas temporales, full scans y demás indicadores relevantes.

30. SARGabilidad
Identificar consultas que utilicen funciones, conversiones, expresiones u operaciones sobre columnas filtradas. Comparar consultas equivalentes y determinar cuáles permiten una utilización más eficiente de los índices. Sustentar las conclusiones mediante planes de ejecución y mediciones.

31. Estadísticas del optimizador
Investigar cómo el motor utiliza estadísticas para estimar cardinalidades y costos. Analizar el efecto de la distribución de los datos y de la actualización de estadísticas sobre los planes de ejecución. Identificar casos en los que el optimizador seleccione un plan distinto al esperado.

32. Costo y selección del plan
Analizar por qué el optimizador puede preferir un recorrido completo en lugar de utilizar un índice, o un índice diferente al propuesto. Explicar las decisiones mediante costos estimados, cardinalidad y selectividad.

33. Optimización de JOIN
Seleccionar consultas con varias tablas. Determinar cómo se realizan los JOIN, qué índices se utilizan, cuántos registros se procesan y qué modificaciones pueden mejorar el rendimiento. Aplicar modificaciones y comparar los resultados.

Parte VII — Optimización de Consultas

34. Selección de consultas a optimizar
Seleccionar al menos 8 consultas que presenten oportunidades de optimización.

35. Proceso de optimización
Para cada consulta: ejecutar la versión original, medirla, analizar el plan, identificar problemas, proponer una hipótesis de mejora, aplicar la modificación, ejecutar nuevamente y comparar resultados.

36. Técnicas de optimización
Las optimizaciones podrán involucrar índices simples y compuestos, índices de cobertura, reescritura de JOIN, SARGabilidad, reestructuración de subconsultas, reducción de datos transportados, paginación y modificaciones justificadas del diseño.

37. Validación de la optimización
Determinar si la modificación produjo realmente una mejora y analizar posibles efectos secundarios, como mayor costo de INSERT, UPDATE o DELETE, mayor almacenamiento o cambios negativos en otras consultas.

Parte VIII — Transacciones y Concurrencia

38. Bloqueos
Experimentar con bloqueos de tablas, filas/registros y operaciones de lectura y escritura. Analizar bloqueos compartidos y exclusivos según el motor utilizado.

39. Concurrencia con dos o más conexiones
Realizar pruebas concurrentes donde una conexión modifique un registro mientras otra intenta modificarlo o leerlo. Documentar esperas, bloqueos y resultados.

40. Niveles de aislamiento
Experimentar con los niveles de aislamiento disponibles. Analizar Dirty Read, Non-repeatable Read y Phantom Read, indicando qué fenómenos aparecen o se evitan en cada nivel.

41. Deadlocks
Diseñar un escenario que produzca un deadlock entre dos transacciones. Identificar las transacciones y recursos involucrados, analizar la detección del deadlock y proponer estrategias para reducir su probabilidad.

42. Identificación y diagnóstico de bloqueos
Investigar las herramientas y consultas disponibles en el motor para identificar bloqueos, transacciones activas, esperas y deadlocks. Documentar los mecanismos utilizados.

Parte IX — Memoria, Servidor y Rendimiento

43. Configuración del servidor
Investigar el archivo de configuración utilizado por el motor seleccionado. Analizar parámetros relacionados con memoria, conexiones, cachés, buffers, ordenamiento, JOIN, tablas temporales, almacenamiento y conexiones.

44. InnoDB Buffer Pool
Para MySQL/MariaDB, investigar el funcionamiento del InnoDB Buffer Pool: información almacenada, relación con RAM, páginas, lecturas desde disco y efecto sobre el rendimiento. Para PostgreSQL, analizar el mecanismo equivalente y sus parámetros relevantes.

45. CPU, disco y red
Diseñar o ejecutar experimentos que permitan identificar si una consulta está limitada por CPU, almacenamiento o red. Relacionar las observaciones con las métricas obtenidas.

46. Connection Pool
Investigar el costo de abrir y cerrar conexiones. Comparar, cuando sea posible, conexiones individuales con reutilización mediante un pool de conexiones y analizar su impacto bajo concurrencia.

47. Slow Query Log y diagnóstico
Configurar y utilizar el mecanismo de registro de consultas lentas disponible en el motor. Generar o identificar consultas lentas, analizarlas mediante EXPLAIN y proponer mejoras.

48. Mantenimiento
Analizar el mantenimiento de tablas, índices y estadísticas a medida que aumenta el volumen de datos. Identificar tareas preventivas que puedan influir en el rendimiento.

Parte X — Escalabilidad, Particionamiento y Estructuras Avanzadas

49. Escalabilidad vertical y horizontal
Investigar y comparar escalabilidad vertical y horizontal. Analizar qué problemas resuelve cada estrategia y sus limitaciones en un sistema relacional.

50. Particionamiento
Investigar estrategias de particionamiento. Implementar, cuando el motor lo permita, un escenario particionado y otro no particionado. Comparar consultas, mantenimiento, almacenamiento y planes de ejecución.

51. Partition pruning
Analizar si las consultas que filtran por la clave de particionamiento permiten evitar el acceso a particiones irrelevantes. Demostrar el comportamiento mediante planes de ejecución.

52. Vistas y materialización
Analizar el uso de vistas para simplificar consultas complejas y, cuando el motor lo soporte, estudiar vistas materializadas o mecanismos equivalentes. Comparar costos de lectura y actualización.

Fecha de Límite de Presentación Jueves 15-10-2026

Fecha de Defensa 16-10-2026

Los grupos deberán estar integrados preferentemente por 3 estudiantes como máximo.